FootPredict

Качество данных и целостность признаков

Информационная система прогнозирования результатов и статистических показателей футбольных матчей на основе машинного обучения

FootPredict v6.2 — исследование

Дата: 09.11.2026

Git commit: 36bd2c86ff05c3ea999a50c84a3a903eeb15080a

Сезоны: 2021/22–2026/27 (оценка моделей 2023/24–2026/27)

Данные на: 2026-11-09

Содержание

1. Цель исследования 3

2. Постановка проблемы 3

3. Гипотезы 3

4. Данные 3

5. Методы 3

5.1. Метрики . . . 4

5.2. Независимый пересчёт признаков . . . 4

5.3. Контролируемая порча признаков . . . 4

5.4. Статус клуба в сезоне . . . 4

5.5. Параметры прогона . . . 4

6. Сырые данные Football-Data 5

6.1. Пропуски . . . 5

6.2. Изменения состава лиг . . . 6

7. Названия клубов и сопоставление 6

7.1. Разные написания в файлах Football-Data . . . 6

7.2. Имена провайдеров . . . 7

7.3. Один клуб под двумя именами . . . 7

8. Переносы, даты, хозяева и гости 7

9. Истории команд и новички 8

10. Независимый пересчёт скользящих признаков 9

11. Хранилище прогнозов 10

11.1. Фантомные прогнозы 03–04.11.2026 . . . 10

11.2. Перенесённые матчи в единой истории . . . 10

11.3. Прочие проверки . . . 11

12. Чувствительность модели к пропускам у одной команды 11

12.1. Воспроизведение фантомов . . . 13

13. Новички против старожилов 14

13.1. Продакшн-история 2026/27 . . . 16

14. Индекс качества данных матча 16

15. Проверка мер для клубов без истории (walk-forward) 16

16. Перечень дефектов 18

16.1. Ошибки продакшна (исправить) . . . 18

16.2. Исследовательские наблюдения . . . 20

17. Отрицательные результаты 20

18. Ограничения 20

19. Выводы 20

20. Рекомендации 21

21. Воспроизведение 21

1. Цель исследования

Проверить всю цепочку данных FootPredict — Football-Data и API-провайдеры → нормализация → сопоставление клубов → история команд → признаки → модели → прогнозы — найти конкретные дефекты данных, отделить ошибки продакшна от исследовательских наблюдений и количественно ответить на вопрос: влияет ли качество данных на вероятности, выбор Main и ROI по реальным ценам.

2. Постановка проблемы

Модели видят только признаки, построенные из истории матчей. Ошибка на любом шаге — другое написание клуба, перенесённый матч, исчезнувший результат, клуб без истории — превращается в пустые или неверные признаки. XGBoost обрабатывает пропуски «как есть», поэтому такие ошибки не вызывают сбоя, а молча меняют прогноз. 03–04.11.2026 это уже произошло: три «фантомных» прогноза были сделаны для клуба, которого модель не знала (KV Mechelen, Sheffield Utd, Oxford Utd).

3. Гипотезы

- **H1.** В сырых файлах и в данных провайдеров есть дефекты (пропуски, дубликаты, переносы, разные написания клубов), которые доходят до признаков и прогнозов.
- **H2.** Скользящие признаки посчитаны правильно: независимый пересчёт из сырых CSV даёт те же значения.
- **H3.** Если у одной команды нет части признаков, вероятности и выбор Main заметно меняются.
- **H4.** Матчи клубов с малой историей (новички из лиг, которые система не загружает) прогнозируются хуже, и Main на них приносит меньше по реальным ценам.
- **H5.** Индекс качества данных матча (доля пустых признаков) связан с ошибкой и с ROI.
- **H6.** Простые меры для клубов без истории (стартовый Elo ниже, история National League) улучшают прогноз их матчей.

4. Данные

Источник	Что это	Объём
local_data/results/<сезон>/<лига>.csv	Football-Data, сезоны 2021/22–2026/27, 21 лига	126 файлов, 38115 строк, 38114 сыгранных
local_data/fixtures/fixtures.csv	Football-Data, ближайшие матчи	10 версий в истории git
local_data/results_live/fixtures.parquet	API-Football, The Odds API, OddsPapi	970 строк (609 с результатом); 33 версий
local_data/results/<сезон>/EC.csv	National League (лига отключена)	2846 строк, угловых нет в 95 %
local_data/processed/features.parquet	признаки до матча (264 столбца)	38266 сыгранных матчей
local_data/predictions/ (4 файла parquet)	снимки, рынки, прогнозы, версии	78753 записей прогнозов, 2217 Main в единой истории
git-история репозитория	ежедневные коммиты данных (только чтение)	версии файлов результатов, фикстур, live-файла и признаков

Сетевых запросов и платных API нет: всё читается из локальных файлов и из истории git. Модели: для 2023/24 и 2024/25 — переобучение продакшн-тренером с параметрами активной версии на всех сезонах до прогнозируемого; для 2025/26 — продакшн-бандл `backtest_2526` (обучен до 01.06.2025); для 2026/27 — активный бандл `prod_20261012` (обучен до 31.05.2026). 2025/26 — «для информации», 2026/27 многократно использовался в исследованиях v6.1 и не является нетронутой проверкой.

5. Методы

5.1. Метрики

Log loss 1X2 на матче i с исходом y_i и вероятностями модели p:

$$LL_i = -\ln p_{i,y(i)}$$

Чтобы трудные матчи не выглядели как «плохие данные», рядом считается log loss рынка — вероятности Bet365 без маржи (пропорционально, $q_k = (1/o_k) / \Sigma\, 1/o_j$) — и избыточный log loss:

$$\Delta LL_i = LL_i(\text{модель}) - LL_i(\text{рынок})$$

Сдвиг вероятностей при порче признаков — расстояние полной вариации между двумя прогнозами одного матча:

$$TV_i = \tfrac{1}{2} \cdot \Sigma_{k \in \{H,D,A\}} \, |p'_{i,k} - p_{i,k}|$$

Смещение ожидаемых очков клуба (положительное = модель переоценивает клуб):

$$b_i = 3 \cdot P(\text{победа}) + P(\text{ничья}) - \text{очки}_{\text{факт}}$$

Main: доля угаданных (WON / (WON + LOST)) и ROI при ставке 1 по реальной цене Bet365 из Football-Data, только для матчей с ценой; PUSH не считается ставкой.

$$ROI = \Sigma \text{ прибыль} / \text{число ставок}, \text{прибыль} = o - 1 \text{ (выигрыш) или } -1 \text{ (проигрыш)}$$

Индекс качества данных матча — доля пустых признаков модели 1X2 (обе стороны). Интервалы — 95 % перцентильный бутстрэп по матчам (2000 повторов); сравнение вариантов на одних и тех же матчах — парный бутстрэп разности; сравнение двух групп — независимый бутстрэп каждой группы. Для шести сравнений групп с базой p-значения поправлены по Холму.

5.2. Независимый пересчёт признаков

Сырые CSV разбираются заново (без `normalise`), строки провайдеров добавляются, только если у Football-Data нет строки этой лиги, дня и клуба; формы, средние сезона и площадки, очки, игры, дни отдыха, число личных встреч считаются векторно (shift + rolling / expanding), Elo — отдельным циклом по опубликованному правилу (K = 20, преимущество поля 60, перенос 0,8, база $1500 - 100 \cdot (\text{уровень} - 1)$).

5.3. Контролируемая порча признаков

У одной стороны группа признаков приводится к виду, который строитель признаков оставляет клубу без этой истории (число игр = 0, средние пусты, Elo = база уровня лиги); производные разности пересчитываются формулами самого строителя; матч прогнозируется теми же моделями и с теми же ценами через продакшн-движок `predict_matches`.

5.4. Статус клуба в сезоне

- **старожилы** — играли в этой лиге в прошлом сезоне;
- **переход внутри наших лиг** — в прошлом сезоне играли в другой нашей лиге той же страны;
- **вернувшиеся** — известны по более ранним сезонам, прошлый сезон провели вне наших лиг;
- **новички извне** — система их раньше не видела (пришли из лиги, которую мы не загружаем).

5.5. Параметры прогона

Параметр	Значение
Сезоны оценки	2023/24, 2024/25, 2025/26, 2026/27
Переобучение	2023/24, 2024/25
Бандлы	backtest_2526, prod_20261012
Бутстрэп / seed / потоков	2000 / 20261109 / 2
Git SHA прогона	36bd2c86ff05c3ea999a50c84a3a903eeb15080a
Библиотеки	numpy 2.2.6, pandas 2.3.3, sklearn 1.7.2, xgboost 3.0.5, matplotlib 3.11.2, reportlab 5.1.0

6. Сырые данные Football-Data

Проверено 126 файлов результатов (38115 строк, 38114 сыгранных матчей). Сезон каждой строки, определённый по дате, совпадает с папкой файла; код лиги — с именем файла.

Проверка	Найдено
Повтор match_id	0
Одна пара хозяев/гостей дважды за сезон (лиги без плей-офф)	0
Клуб в двух матчах одной лиги в один день	0
Сезон по дате ≠ папка файла	0
Код лиги ≠ имя файла	0
Удары в створ > ударов	7
Голов больше ударов в створ (автоголы, допустимо)	180 (0.47 %)
Отрицательные значения	0
Строка без счёта в файле результатов	F2-20251205-bastia-red-star
Два матча клуба с разницей ≤ 1 день	T1-20230226-umraniyespor-ad-demirspor
Сыгранные матчи без статистики	42, из них похожих на техническое 3:0 — 33

6.1. Пропуски

Доля сыгранных матчей, где пусто хотя бы одно поле группы (все лиги и сезоны): удары 0.11 %, угловые 0.11 %, фолы 0.12 %, карточки 0.10 %, цена 1X2 0.21 %, тотал 2,5 0.22 %, азиатская фора 0.53 %. Голы есть всегда. Пропуски статистики сосредоточены в Турции 2022/23: 29 матчей без статистики — технические результаты после снятия клубов (землетрясение); эти 3:0 входят в форму и Elo как настоящие матчи.

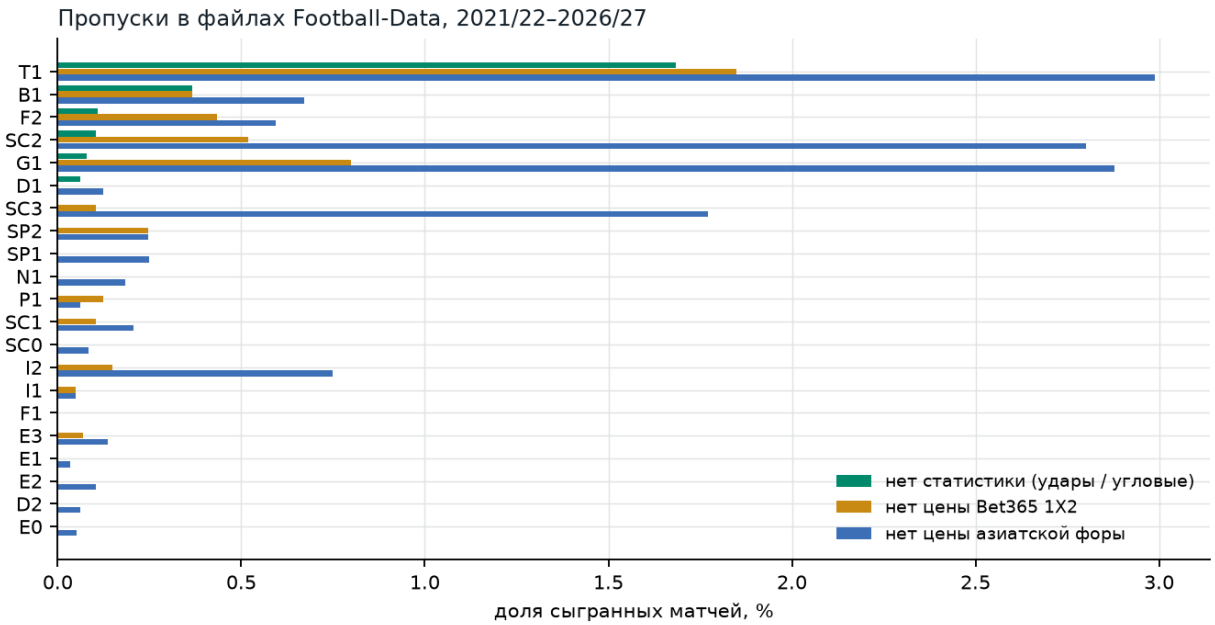


Рис. 1. Доля сыгранных матчей с пропусками по лигам (2021/22–2026/27).

Сезон	Удары	Угловые	Цена 1X2	Цена форы
2021/22	0.05 %	0.05 %	0.22 %	0.82 %
2022/23	0.44 %	0.44 %	0.55 %	0.71 %
2023/24	0.03 %	0.03 %	0.10 %	0.51 %
2024/25	0.06 %	0.06 %	0.04 %	0.39 %
2025/26	0.00 %	0.00 %	0.17 %	0.32 %
2026/27	0.00 %	0.00 %	0.05 %	0.15 %

Табл. 2. Доля сыгранных матчей с пропусками по сезонам (все 21 лига).

6.2. Изменения состава лиг

Лига	Сезон	Клубов было	Клубов стало
B1	2023/24	18	16
B1	2026/27	16	18
F1	2023/24	20	18
F2	2024/25	20	18
T1	2022/23	20	19
T1	2023/24	19	20
T1	2024/25	20	19
T1	2025/26	19	18

В Бельгии и Греции после регулярного сезона идёт плей-офф: его матчи входят в таблицу сезона как обычные (36–41 игра на клуб вместо 30); признаки «по сезону» смешивают оба этапа.

7. Названия клубов и сопоставление

7.1. Разные написания в файлах Football-Data

Коммит (UTC)	Файл	Лига / дата	Матч	Имя	Правило даёт
bf7ccd0 2026-11-03 17:13	fixtures.csv	B1 2026-11-04	Kortrijk – KV Mechelen	KV Mechelen	Mechelen
bf7ccd0 2026-11-03 17:13	fixtures.csv	E1 2026-11-03	Preston – Sheffield Utd	Sheffield Utd	Sheffield United
bf7ccd0 2026-11-03 17:13	fixtures.csv	E2 2026-11-04	Oxford Utd – Reading	Oxford Utd	Oxford

Коммит (UTC)	Файл	Лига / дата	Матч	Имя	Правило даёт
9bd3c19 2026-11-05 08:11	results/2627/B1.csv			KV Mechelen (1 сыгр.)	новое имя клуба посреди сезона
13f6799 2026-11-06 08:15	results/2627/B1.csv		B1-20261104-kortrijk-kv-mechelen		сыгранный матч исчез
9bd3c19 2026-11-05 08:11	results/2627/E1.csv			Sheffield Utd (1 сыгр.)	новое имя клуба посреди сезона
13f6799 2026-11-06 08:15	results/2627/E1.csv		E1-20261103-preston-sheffield-utd		сыгранный матч исчез
9bd3c19 2026-11-05 08:11	results/2627/E2.csv			Oxford Utd (1 сыгр.)	новое имя клуба посреди сезона
13f6799 2026-11-06 08:15	results/2627/E2.csv		E2-20261104-oxford-utd-reading		сыгранный матч исчез

Во всех 10 версиях файла фикстур и 143 версиях файлов результатов 2026/27 разное написание встретилось один раз — 03–05.11.2026 — сразу в трёх лигах. Важная деталь: 05.11 (коммит 9bd3c19) неверные имена были и в **файлах результатов** — сыгранные матчи «Kortrijk – KV Mechelen», «Preston – Sheffield Utd», «Oxford Utd – Reading» на сутки появились как результаты клубов без истории, а настоящие Mechelen, Sheffield United, Oxford на сутки лишились этого матча. 06.11 Football-Data исправил имена. `harmonise_fixture_names` (v6.1) приводит к единому написанию только фикстуры; строки результатов он не трогает.

7.2. Имена провайдеров

Провайдер	Лига	Имя провайдера	Правило даёт	Кандидаты Football-Data (матчей 2026/27)
api_football	G1	OFI	—	OFI Crete (9)
api_football	I2	Vicenza Virtus	—	Vicenza (10); Virtus Entella (10)
api_football	SP2	Real Sociedad II	—	Sociedad B (12)

Эти три имени API-Football (файл `unmatched_teams.csv` последнего прогона) не сопоставляются, поэтому фикстуры и свежие результаты OFI Crete, Vicenza и Sociedad B от API-Football пропускаются — их результаты приходят только с Football-Data.

Файл `team_id_conflicts.csv` сообщает конфликт: OddsPapi id 5044 записан как Belgium|Mechelen, а имя говорит Belgium|KV Mechelen («Yellow-Red KV Mechelen»). По истории git файл последний раз менялся 06.11 и с тех пор не перезаписывался: `collect` пишет его только когда конфликты есть и никогда не удаляет (в отличие от `unmatched_teams.csv`). Конфликт — след того же неверного имени KV Mechelen, которое 03–05.11 было в списке известных клубов.

7.3. Один клуб под двумя именами

Страна	Сезон	Новое имя (лига)	Прежнее имя (лига)
Scotland	2022/23	FC Edinburgh (SC2)	Edinburgh City (SC3)
Scotland	2023/24	Edinburgh City (SC2)	FC Edinburgh (SC2)

Edinburgh City в сезоне 2022/23 назывался FC Edinburgh, а потом вернул старое имя. Для системы это два клуба: в 2022/23 — 36 матчей «новичка» без истории, в 2023/24 — история годичной давности. Других пар (общие слова длиной ≥ 5 букв у исчезнувшего и появившегося клуба одной страны) нет; Notts County / Newport County, Le Mans / Le Havre и т. п. — разные клубы.

8. Переносы, даты, хозяева и гости

Сравнение API-провайдеров с Football-Data	Результат
Матчи с одинаковым id: несовпадение счёта	0 из 457

Сравнение API-провайдеров с Football-Data	Результат
Несовпадение времени начала	0 из 791
Хозяева и гости переставлены	0
Дата провайдера ≠ дате Football-Data (та же пара, ≤ 60 дней)	8
Результаты только от API (Football-Data ещё не опубликовал)	152
…из них старше последней даты Football-Data в лиге	0
Несыгранные фикстуры с датой в прошлом в таблице признаков	9

Перенесённые матчи (дата провайдера и фактическая дата)

match_id провайдера	Провайдер	Дата провайдера	Дата FD	Дней
F1-20261024-toulouse-troyes	the_odds_api	2026-10-24	2026-10-25	1
F2-20261024-montpellier-red-star	the_odds_api	2026-10-24	2026-10-26	2
F1-20261025-paris-sg-lyon	the_odds_api	2026-10-25	2026-10-26	1
F1-20261031-nice-rennes	the_odds_api	2026-10-31	2026-10-30	-1
F1-20261031-lyon-angers	the_odds_api	2026-10-31	2026-11-01	1
F1-20261031-lorient-brest	the_odds_api	2026-10-31	2026-11-02	2
B1-20261023-kortrijk-mechelen	the_odds_api	2026-10-23	2026-11-04	12
F2-20261031-reims-sochaux	oddspapi	2026-10-31	2026-11-02	2

Изменения в live-файле между ежедневными версиями

Коммит (UTC)	Изменение	match_id	Детали
942195a 2026-10-22 11:28	строка удалена	SC0-20261017-st-johnstone-dundee	был сыгран (api_football)
942195a 2026-10-22 11:28	строка удалена	SP1-20261024-santander-barcelona	не сыгран (oddspapi)
bf7ccd0 2026-11-03 17:13	результат снова стал фикстурой	SP2-20261102-tenerife-andorra	2-2 (api_football -> api_football)

Строка «SC0-20261017-st-johnstone-dundee» — исторический дефект, исправленный 22.10: API-Football 16–22.10 отнёс матч St Johnstone – Dundee United к клубу Dundee (сыгранный «фантом» 1:1 был в признаках пять дней). Матч «SP2-20261102-tenerife-andorra» 03.11 из результата 2:2 снова стал фикстурой; у Football-Data этого матча нет до сих пор, а прогноз на него уже рассчитан как выигрыш.

Несыгранные фикстуры с прошедшей датой

match_id	Источник	Отставание, дней
SP1-20261010-vallecano-ath-bilbao	api_football	29
G1-20261017-atromitos-aek	the_odds_api	22
SC1-20261024-morton-ayr	oddspapi	14
SC2-20261024-cove-rangers-east-kilbride	api_football	14
SC0-20261031-dundee-united-hearts	oddspapi	8
SP2-20261101-tenerife-andorra	oddspapi	7
SP2-20261102-tenerife-andorra	api_football	6
SP2-20261106-castellon-eibar	oddspapi	2
SP2-20261107-burgos-celta-b	oddspapi	1

Это отложенные матчи без новой даты и устаревшие даты провайдеров. Признаки по ним не обновляются и прогнозы не делаются (старт в прошлом), но Tenerife – Andorra присутствует дважды (01.11 от OddsPapi и 02.11 от API-Football).

9. Истории команд и новички

Сезон	Старожилы	Переход внутри наших лиг	Вернувшиеся	Новички извне
2022/23	300	51	0	28
2023/24	295	52	8	21

Сезон	Старожилы	Переход внутри наших лиг	Вернувшиеся	Новички извне
2024/25	293	52	8	20
2025/26	292	52	12	16
2026/27	297	50	13	14

Табл. Клубы-сезоны по статусу (2021/22 — первый сезон данных, статус не определяется).

Новички извне и вернувшиеся по лигам (все сезоны): B1 9, D2 13, E3 10, F2 11, G1 9, I2 20, N1 15, P1 13, SC2 2, SC3 3, SP2 20, T1 15. В E0, SP1, I1, D1, F1 и SC0 их нет: туда поднимаются только клубы наших же вторых лиг. Новички извне приходят в низшие загруженные дивизионы (из National League, Primera RFEF, Serie C, 3. Liga, National и т. п.) и в высшие лиги стран, где загружена одна лига (B1, N1, P1, T1, G1).

В первом матче новичка извне (99 случаев) у модели нет ни одной формы (form10_n = 0.0), нет таблицы сезона, нет дней отдыха, а Elo равен базе уровня лиги: в среднем 1418, на 5.7 пункта ниже среднего Elo лиги — то есть новичок стартует как средний клуб. Фактически новички извне набирают 1.21 очка за матч против 1.40 у старожилов. У вернувшихся (41 первых матчей) форма есть, но ей в медиане 463 дней (от 433 до 1568).

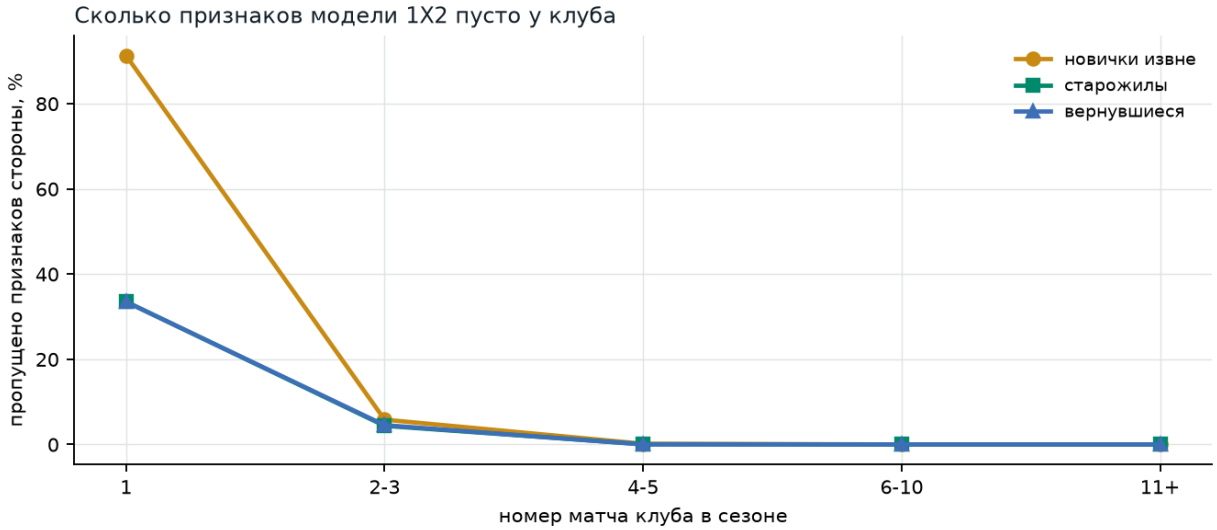


Рис. 2. Доля пустых признаков модели 1X2 у одной стороны по номеру матча клуба в сезоне. В первом туре пусто около трети у всех (нет таблицы сезона); у новичка извне — почти всё.

10. Независимый пересчёт скользящих признаков

Независимая таблица содержит 38266 сыгранных матчей, продакшн — 38266; общих 38266 (только в продакшне 0, только в пересчёте 0). Сравнено 37 признаков, 1415842 значений; расхождений — 0.

Признак	Сравнено	Оба пусты	Пусто только в одном	Разные значения	Макс. |разница|
h/a_form5_n	38266	0	0	0	0.0e+00
h/a_form10_n	38266	0	0	0	0.0e+00
h/a_form15_n	38266	0	0	0	0.0e+00
h/a_form5_ppg	38266	232	0	0	0.0e+00
h/a_form10_gf	38266	232	0	0	0.0e+00
h/a_form10_ga	38266	232	0	0	0.0e+00
h/a_form10_shots_for	38266	238	0	0	0.0e+00
h/a_form10_corners_for	38266	238	0	0	0.0e+00
h/a_form15_sot_against	38266	233	0	0	0.0e+00
h/a_freq_over25	38266	232	0	0	0.0e+00
h/a_season_games	38266	0	0	0	0.0e+00

Признак	Сравнено	Оба пусты	Пусто только в одном	Разные значения	Макс. |разница|
h/a_points	38266	1129	0	0	0.0e+00
h/a_season_ppg	38266	1129	0	0	0.0e+00
h/a_season_gf	38266	1129	0	0	0.0e+00
h/a_venue_gf	38266	2254	0	0	0.0e+00
h/a_venue_form5_gf	38266	479	0	0	0.0e+00
h/a_rest_days	38266	232	0	0	0.0e+00
h2h_n	38266	0	0	0	0.0e+00
h_elo	38266	0	0	0	4.5e-13
a_elo	38266	0	0	0	4.5e-13

Для пар h_/a_ показана строка хозяев; строка гостей совпадает по числу расхождений (все нули — в файле `recompute_summary.csv`).

H2 подтверждается: скользящие признаки, таблица сезона, дни отдыха, личные встречи и Elo в `features.parquet` в точности совпадают с независимым пересчётом из сырых файлов. Утечки результата матча в его признаки нет; дефекты связаны не с вычислением, а с входными данными.

11. Хранилище прогнозов

11.1. Фантомные прогнозы 03–04.11.2026

Матч	Вид	Создан (UTC)	П1 / Х / П2	xG	Main	Цена	Итог
B1-20261104-kortrijk-kv-mechelen	фантом	11-04 17:29	0.34 / 0.28 / 0.38	1.34–1.15	тотал 2,5 меньше	2.00	проигр.
B1-20261104-kortrijk-mechelen	настоящий	11-02 19:35	0.39 / 0.30 / 0.31	1.29–1.20	тотал 3,5 меньше	1.33	проигр.
E1-20261103-preston-sheffield-utd	фантом	11-03 17:13	0.31 / 0.28 / 0.41	1.32–1.20	тотал 1,5 больше	—	выигр.
E1-20261103-preston-sheffield-united	настоящий	11-02 19:35	0.29 / 0.26 / 0.45	1.14–1.53	тотал 3,5 меньше	1.41	проигр.
E2-20261104-oxford-utd-reading	фантом	11-04 17:29	0.28 / 0.26 / 0.46	1.21–1.75	тотал 2,5 больше	1.70	проигр.
E2-20261104-oxford-reading	настоящий	11-02 19:35	0.37 / 0.28 / 0.35	1.51–1.37	тотал 3,5 меньше	1.41	выигр.

Фантомы были не только сделаны, но и рассчитаны: 05.11 их match_id появились в файлах результатов Football-Data. В единой истории их исключает `same_day_duplicates`. Во всех трёх случаях Main фантома отличался от Main настоящего матча.

Если бы фантомы остались в истории: 2200 ставок Main, ROI -4.20 % против 2198 и -4.11 % сейчас.

11.2. Перенесённые матчи в единой истории

`rescheduled_duplicates` объединяет 11 пар прогнозов одного перенесённого матча и отбрасывает 11. Правило «оставить самую позднюю дату» ошибается, когда поздняя дата провайдера устарела, а матч сыгран раньше: F1-20261031-nice-rennes. Для F1 Nice – Rennes сыгран 30.10 (5:2); история держит прогноз на 31.10 — он никогда не будет рассчитан и через 21 день станет VOID, — а отброшен рассчитанный прогноз на 30.10 (Main «меньше 3,5» по 1,46, проигрыш).

С исправленным правилом (сначала записанный до матча прогноз, затем прогноз, чей match_id — сыгранный матч, затем поздняя дата): 2199 ставок, ROI -4.16 % вместо 2198 и -4.11 %.

match_id	Оставлен сейчас	Оставит исправление	Источник	Статус	Цена
B1-20261104-kortrijk-mechelen	да	да	live	проигр.	1.33
B1-20261023-kortrijk-mechelen			live	проигр.	1.33
F1-20261025-toulouse-troyes	да	да	live	выигр.	1.64
F1-20261024-toulouse-troyes			live	выигр.	—
F1-20261026-paris-sg-lyon	да	да	live	выигр.	1.41
F1-20261025-paris-sg-lyon			live	выигр.	1.30
F1-20261031-nice-rennes	да		live	ожидает	—
F1-20261030-nice-rennes		да	live	проигр.	1.46
F1-20261101-lyon-angers	да	да	live	выигр.	1.39
F1-20261031-lyon-angers			live	выигр.	—
F1-20261102-lorient-brest	да	да	live	выигр.	1.33
F1-20261031-lorient-brest			live	выигр.	—
F2-20261026-montpellier-red-star	да	да	live	выигр.	1.33
F2-20261024-montpellier-red-star			live	выигр.	—
F2-20261102-reims-sochaux	да	да	live	выигр.	1.37
F2-20261031-reims-sochaux			live	выигр.	1.37
P1-20261108-nacional-academico-viseu	да	да	live	проигр.	1.30
P1-20261107-nacional-academico-viseu			live	проигр.	1.30
SP2-20261003-sabadell-andorra	да	да	live	проигр.	—
SP2-20261004-sabadell-andorra			backfill	проигр.	1.30
SP2-20261109-las-palmas-eldense	да	да	live	ожидает	1.37
SP2-20261108-las-palmas-eldense			live	ожидает	1.37

11.3. Прочие проверки

Проверка	Результат
Main с match_id, которого нет в таблице признаков	13 (переносы и фантомы)
Рассчитанные прогнозы матча без результата	SP2-20261101-tenerife-andorra (WON, 2-2)
Инварианты `check_history`	profit without a price: 8
VOID с прибылью 0 без цены	8 записей (G1 Atromitos – AEK)
Live Main, проверенные на свежесть данных	826
…из них без результата предыдущего матча клуба	1 (0.12 %), отставание ≤ 1 дн.

Свежесть: для каждого записанного Main единой истории взята таблица признаков, закоммиченная тем же ежедневным прогоном, и проверено, были ли в ней все результаты обоих клубов за предыдущие дни. Пропуск найден лишь однажды, то есть задержка результатов на прогнозы почти не влияет.

12. Чувствительность модели к пропускам у одной команды

Все 23672 сыгранных матчей 2023/24–2026/27; база — неиспорченный прогноз того же матча той же моделью.

Что пусто	Средний TV	TV 90 %	ΔP(П1)	ΔP(П2)	Δ log loss [95 % ДИ]	Main изменился
Elo = базовый — гости	0.037	0.092	+0.007	-0.014	$+6.8\ [+5.3;\ +8.2]\cdot10^{-3}$	28 %
Elo = базовый — хозяева	0.038	0.095	-0.014	+0.005	$+8.7\ [+7.2;\ +10.3]\cdot10^{-3}$	28 %
форма — гости	0.037	0.071	-0.010	+0.000	$+3.3\ [+2.1;\ +4.5]\cdot10^{-3}$	55 %

Что пусто	Средний TV	TV 90 %	ΔP(П1)	ΔP(П2)	Δ log loss [95 % ДИ]	Main изменился
форма — хозяева	0.062	0.108	-0.047	+0.056	+13.4 [+11.4; +15.3]·10⁻³	70 %
личные встречи (пара)	0.003	0.007	+0.000	-0.000	+0.1 [+0.0; +0.3]·10⁻³	6 %
всё (новичок) — гости	0.099	0.201	-0.015	-0.005	+35.5 [+32.1; +38.8]·10⁻³	66 %
всё (новичок) — хозяева	0.115	0.261	-0.080	+0.080	+57.4 [+53.5; +61.2]·10⁻³	74 %
дни отдыха — гости	0.001	0.002	-0.000	+0.001	+0.0 [-0.0; +0.1]·10⁻³	5 %
дни отдыха — хозяева	0.002	0.003	-0.001	+0.001	+0.0 [-0.0; +0.1]·10⁻³	7 %
таблица сезона — гости	0.027	0.051	-0.006	+0.006	+2.5 [+1.5; +3.4]·10⁻³	32 %
таблица сезона — хозяева	0.025	0.051	-0.003	+0.001	+3.0 [+2.1; +3.9]·10⁻³	34 %
удары/угловые — гости	0.042	0.083	-0.013	+0.012	+6.0 [+4.6; +7.4]·10⁻³	53 %
удары/угловые — хозяева	0.057	0.110	-0.042	+0.046	+13.1 [+11.2; +14.9]·10⁻³	61 %

Что пусто	Ставок база / вар.	Доля угаданных база / вар.	ROI база	ROI вариант	Δ ROI, п.п. [95 % ДИ]
Elo = базовый — гости	12111 / 11732	64.4 % / 63.9 %	-3.67 %	-3.44 %	+0.22 [-0.85; +1.46]
Elo = базовый — хозяева	12111 / 10783	64.4 % / 63.8 %	-3.67 %	-4.44 %	-0.77 [-1.98; +0.44]
форма — гости	12111 / 11927	64.4 % / 63.6 %	-3.67 %	-3.46 %	+0.20 [-1.53; +1.79]
форма — хозяева	12111 / 15120	64.4 % / 60.4 %	-3.67 %	-3.79 %	-0.12 [-1.81; +1.67]
личные встречи (пара)	12111 / 11821	64.4 % / 64.6 %	-3.67 %	-3.59 %	+0.08 [-0.41; +0.56]
всё (новичок) — гости	12111 / 10376	64.4 % / 62.1 %	-3.67 %	-2.48 %	+1.19 [-0.85; +3.31]
всё (новичок) — хозяева	12111 / 11618	64.4 % / 60.8 %	-3.67 %	-4.40 %	-0.74 [-2.99; +1.52]
дни отдыха — гости	12111 / 12001	64.4 % / 64.4 %	-3.67 %	-3.64 %	+0.03 [-0.42; +0.46]
дни отдыха — хозяева	12111 / 11853	64.4 % / 64.5 %	-3.67 %	-3.58 %	+0.09 [-0.38; +0.56]
таблица сезона — гости	12111 / 11014	64.4 % / 63.8 %	-3.67 %	-3.87 %	-0.20 [-1.39; +1.03]
таблица сезона — хозяева	12111 / 11027	64.4 % / 64.0 %	-3.67 %	-4.14 %	-0.47 [-1.73; +0.74]
удары/угловые — гости	12111 / 10577	64.4 % / 64.5 %	-3.67 %	-3.38 %	+0.29 [-1.39; +1.98]
удары/угловые — хозяева	12111 / 12524	64.4 % / 62.3 %	-3.67 %	-4.02 %	-0.35 [-2.09; +1.40]



Рис. 3. Рост log loss и доля матчей, где сменился Main, когда у одной стороны пуста группа признаков.

H3 подтверждается. Если клуб для модели «новый», вероятности сдвигаются в среднем на 0.115 (хозяева) и 0.099 (гости) по TV, log loss растёт на $57.4 \cdot 10^{-3}$ и $35.5 \cdot 10^{-3}$, Main меняется в 74 % и 66 % матчей. Больше всего значат форма и статистика ударов/угловых; дни отдыха и личные встречи почти не влияют. Main очень чувствителен: замена одного Elo меняет его примерно в 28 % матчей, потому что кандидаты рынков близки по оценке и малый сдвиг меняет лидера.

При этом ROI Main почти не меняется: у 13 из 13 вариантов порчи 95 % интервал разности ROI включает 0 (разности от -0.77 до +1.19 п.п.). Main выбирает другой рынок, но с похожей ценой и похожей ожидаемой доходностью — на итог по реальным ценам пропуски у одной стороны в среднем не влияют, хотя вероятности становятся хуже.

12.1. Воспроизведение фантомов

Матч	Вариант	П1 / Х / П2 (пересчёт)	Сохранённый прогноз	Макс. |Δp|
B1-20261104-kortrijk-mechelen	признаки настоящего матча	0.388 / 0.299 / 0.313	B1-20261104-kortrijk-mechelen: 0.388 / 0.299 / 0.313	0.000
B1-20261104-kortrijk-mechelen	сторона = новичок	0.337 / 0.283 / 0.380	B1-20261104-kortrijk-kv-mechelen: 0.337 / 0.283 / 0.380	0.000
E1-20261103-preston-sheffield-united	признаки настоящего матча	0.285 / 0.264 / 0.450	E1-20261103-preston-sheffield-united: 0.285 / 0.264 / 0.450	0.000
E1-20261103-preston-sheffield-united	сторона = новичок	0.311 / 0.276 / 0.414	E1-20261103-preston-sheffield-utd: 0.311 / 0.276 / 0.414	0.000
E2-20261104-oxford-reading	признаки настоящего матча	0.369 / 0.277 / 0.354	E2-20261104-oxford-reading: 0.369 / 0.277 / 0.354	0.000
E2-20261104-oxford-reading	сторона = новичок	0.277 / 0.261 / 0.462	E2-20261104-oxford-utd-reading: 0.277 / 0.260 / 0.463	0.000

Порча «сторона = новичок» на строке настоящего матча и продакшн-бандл воспроизводят сохранённые вероятности фантомов: наибольшее расхождение по всем шести прогнозам 0.0003. Значит, фантом — это ровно «клуб без истории» (пустые формы и таблица, базовый Elo, нет личных встреч), и порча признаков в разделе 12 описывает реальный механизм дефекта, а не выдуманный.

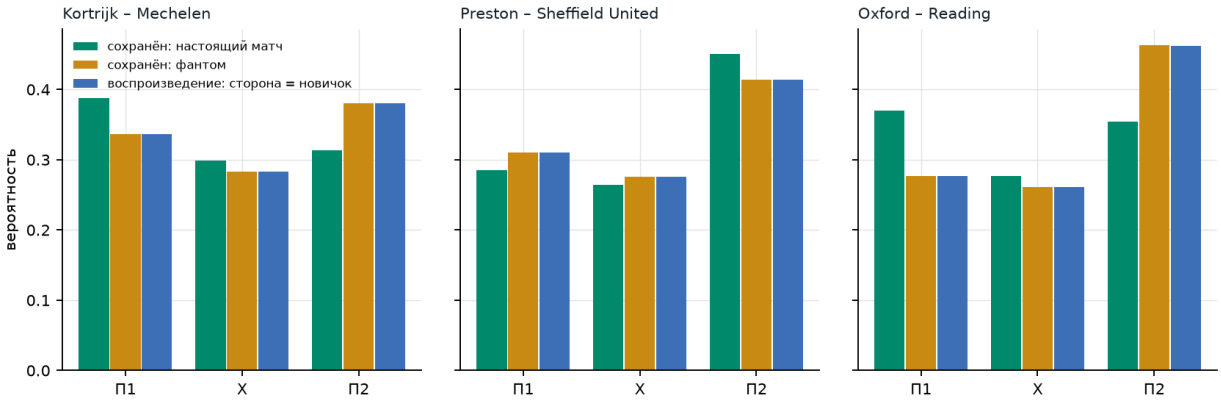


Рис. 4. Вероятности настоящего матча, фантома и воспроизведения.

13. Новички против старожилов

Группа (худший статус в матче)	Матчи	Log loss	Изб. log loss ×10⁻³ [95 % ДИ]	Ставок	Угадано	ROI Main [95 % ДИ]
старожилы, матчи 1-10	4646	0.9965	+16.2 [+11.9; +20.5]	2488	63.9 %	-3.7 % [-7.0; -0.6]
старожилы, матчи 11+	9800	1.0080	+9.1 [+6.4; +11.7]	5163	64.7 %	-3.2 % [-5.4; -0.9]
переход внутри наших лиг, матчи 1-10	1798	1.0327	+20.0 [+10.2; +30.1]	892	64.6 %	+3.0 % [-2.8; +9.0]
переход внутри наших лиг, матчи 11+	4150	1.0049	+12.9 [+8.9; +17.1]	1994	64.5 %	-4.6 % [-8.5; -1.0]
вернувшиеся, матчи 1-10	373	0.9905	-0.1 [-16.5; +17.3]	191	62.2 %	-6.0 % [-17.4; +6.2]
вернувшиеся, матчи 11+	695	0.9986	+9.3 [-2.5; +20.6]	357	64.1 %	-1.8 % [-10.5; +6.2]
новички извне, матчи 1-10	685	1.0603	+26.6 [+11.5; +41.4]	360	62.1 %	-11.5 % [-20.7; -2.1]
новички извне, матчи 11+	1525	1.0388	+13.8 [+6.7; +20.4]	666	64.6 %	-9.1 % [-15.5; -2.9]
новички извне, матчи все	2210	1.0454	+17.8 [+11.6; +24.3]	1026	63.8 %	-9.9 % [-15.1; -4.8]
старожилы, матчи все	14446	1.0043	+11.4 [+9.2; +13.8]	7651	64.5 %	-3.4 % [-5.2; -1.5]

«Матчи 1-10» — первые десять матчей сезона клуба этой группы; старожилы для сравнения берутся из матчей, где у обеих команд ≤ 10 матчей в сезоне, — начало сезона трудно для всех.

Сравнение со старожилами	Δ log loss ×10⁻³	Δ изб. log loss ×10⁻³	Холм p	Δ ROI Main, п.п.	Δ доли угаданных, п.п.
новички извне, 1-10	+63.8 [+34.6; +92.8]	+10.4 [-4.7; +25.2]	0.70	-7.8 [-17.4; +2.3]	-1.8 [-5.7; +2.0]
новички извне, 11+	+30.8 [+11.2; +49.8]	+4.7 [-2.6; +12.3]	0.70	-5.9 [-12.4; +0.7]	-0.2 [-2.9; +2.3]
вернувшиеся, 1-10	-6.0 [-46.2; +37.1]	-16.3 [-32.2; +1.3]	0.43	-2.3 [-14.9; +10.3]	-1.7 [-6.8; +3.3]
вернувшиеся, 11+	-9.4 [-41.1; +22.1]	+0.2 [-12.0; +11.2]	1.00	+1.4 [-7.1; +9.7]	-0.6 [-4.5; +2.9]
переход внутри наших лиг, 1-10	+36.1 [+17.2; +54.3]	+3.8 [-6.8; +14.5]	0.95	+6.7 [+0.0; +13.5]	+0.7 [-1.9; +3.2]
переход внутри наших лиг, 11+	-3.1 [-17.8; +10.7]	+3.8 [-1.1; +8.6]	0.70	-1.4 [-5.7; +3.1]	-0.2 [-2.0; +1.6]

Матчи новичков извне прогнозируются хуже: log loss выше на +63.8 [+34.6; +92.8]·10⁻³ (интервал не включает 0). Но рынку они тоже даются труднее: избыточный log loss +10.4 [-4.7; +25.2]·10⁻³ — в пределах шума, интервал включает 0. Main на этих матчах: Δ ROI -7.8 п.п. [-17.4; +2.3] — в пределах шума, интервал включает 0.

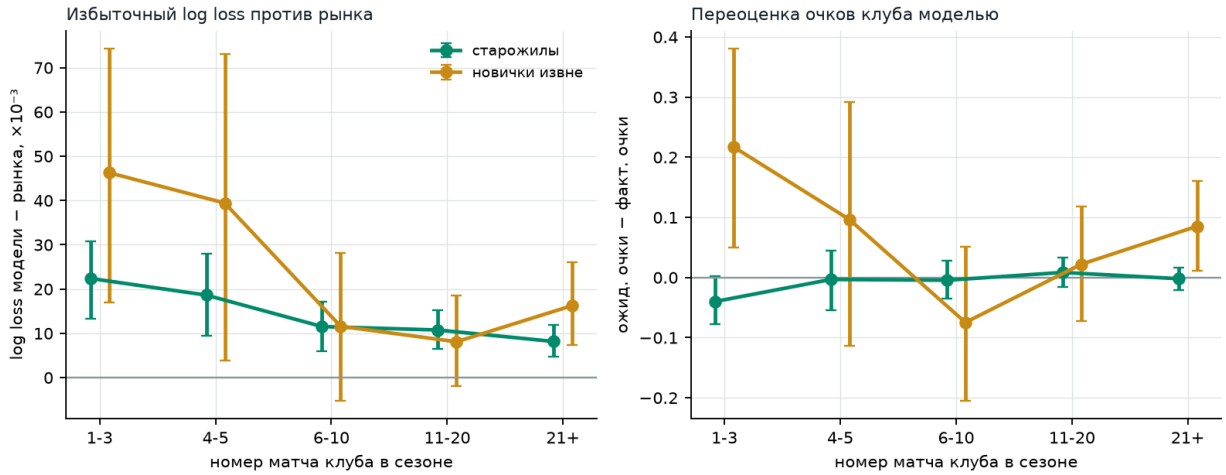


Рис. 5. Избыточный log loss против рынка и переоценка ожидаемых очков по номеру матча клуба в сезоне (95 % ДИ).

Статус клуба	Сторон-матчей	P(победа) модель	P(победа) рынок	Частота побед	Смещение очков, все	Смещение, матчи 1-10
старожилы	37052	0.380	0.380	0.380	-0.004 [-0.016; +0.009]	-0.015 [-0.036; +0.007]
переход внутри наших лиг	6830	0.355	0.358	0.352	+0.011 [-0.017; +0.042]	+0.041 [-0.011; +0.095]
вернувшиеся	1172	0.289	0.294	0.285	+0.011 [-0.058; +0.075]	+0.065 [-0.046; +0.176]
новички извне	2290	0.324	0.318	0.300	+0.057 [+0.009; +0.108]	+0.047 [-0.045; +0.136]

В первых трёх матчах новичка извне модель ждёт от него на +0.217 очка больше, чем он набирает [+0.050; +0.380]: P(победа) модели 0.315, рынка 0.292, факт 0.254. Причина видна в разделе 9: новичок стартует со средним Elo лиги, а играет слабее среднего.

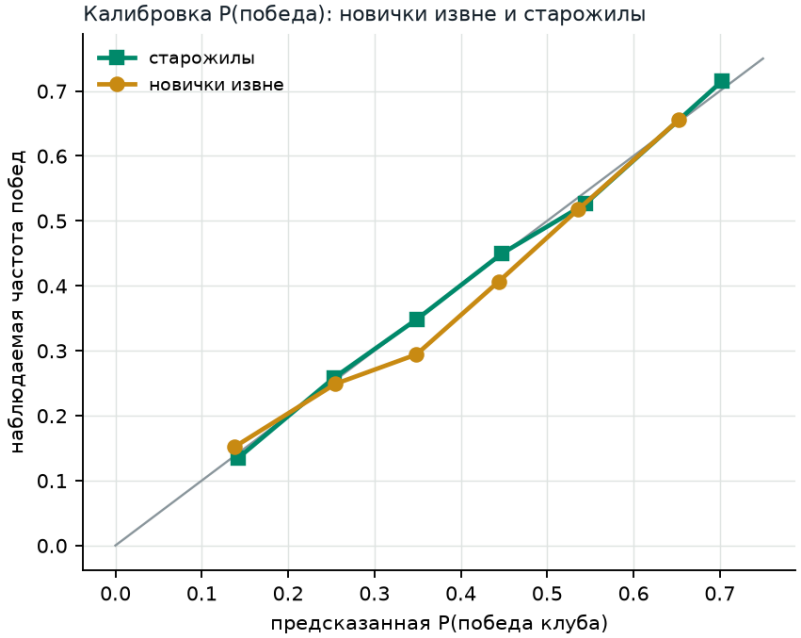


Рис. 6. Калибровка P(победа клуба) для новичков извне и старожилов.

13.1. Продакшн-история 2026/27

Группа (2026/27, единая история)	Ставок	Угадано	ROI [95 % ДИ]
старожилы	1368	66.9 %	-3.2 % [-7.0; +0.5]
переход внутри наших лиг	538	65.1 %	-5.4 % [-11.4; +0.4]
вернувшиеся	140	67.1 %	-5.4 % [-16.9; +5.9]
новички извне	152	65.8 %	-6.4 % [-18.0; +4.2]

Разность ROI «новички извне + вернувшиеся» минус остальные: -2.1 п.п. [-10.9; +6.4] — в пределах шума, интервал включает 0. Цены — записанные до матча и восстановленные из архива OddsPapi.

14. Индекс качества данных матча

Пустых признаков	Матчи	Log loss	Изб. log loss ×10⁻³ [95 % ДИ]	Ставок	Угадано	ROI Main [95 % ДИ]
0 %	19713	1.0057	+11.7 [+9.8; +13.7]	10175	64.5 %	-3.8 % [-5.4; -2.2]
0–5 %	2494	1.0353	+12.7 [+6.5; +19.3]	1171	64.2 %	-2.9 % [-7.9; +2.0]
5–20 %	709	1.0288	+30.2 [+14.5; +45.2]	377	64.4 %	-2.9 % [-12.0; +5.7]
20–50 %	688	1.0149	+18.8 [+3.4; +33.7]	357	62.2 %	-1.6 % [-11.1; +7.3]
> 50 %	68	1.0719	+34.2 [-29.1; +98.3]	31	57.4 %	-18.7 % [-52.3; +14.9]

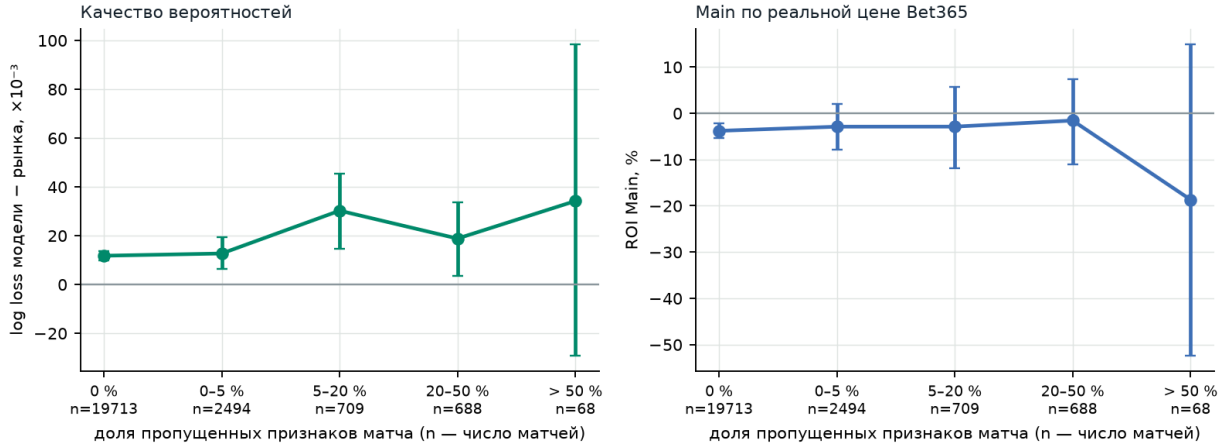


Рис. 7. Избыточный log loss и ROI Main по доле пустых признаков матча.

Матчей с > 20 % пустых признаков — 3.2 %. Против матчей без пропусков: избыточный log loss +8.4 [-6.5; +23.7]·10⁻³ (в пределах шума, интервал включает 0), доля угаданных Main -2.8 п.п. [-6.1; +0.8] (в пределах шума, интервал включает 0), ROI Main +0.9 п.п. [-8.0; +10.2] (в пределах шума, интервал включает 0). Ранговая корреляция индекса с избыточным log loss 0.022. Внутри первых пяти туров (где пропуски есть у всех) матчи с > 50 % пропусков против ≤ 20 %: +12.2 [-52.8; +75.9]·10⁻³ по избыточному log loss, -16.1 п.п. [-47.9; +20.0] по ROI — выборка мала.

Доля матчей, где новичок извне или вернувшийся клуб играет один из первых десяти матчей сезона: 2023/24 — 3.8 %, 2024/25 — 3.7 %, 2025/26 — 3.7 %, 2026/27 — 11.6 %. В 2026/27 (сезон только начался) она втрое выше, поэтому эффект новичков сейчас заметнее.

15. Проверка мер для клубов без истории (walk-forward)

Строитель признаков, запущенный заново на тех же файлах, воспроизводит продакшн-таблицу: 38284 строк против 38284, те же match_id — да, различающихся числовых ячеек — 0. Варианты: стартовый Elo клуба, впервые появившегося после первого сезона данных, ниже базы на 50 или 100; история National League (EC) в состоянии строителя (без обучения и прогноза на EC). Для каждого варианта признаки строятся

заново, модели переобучаются на сезонах до прогнозируемого, оценка — на тех же матчах, что и база. Правило отбора объявлено до прогона: вариант перспективен, только если на 2023/24 и на 2024/25 он снижает log loss матчей новичков извне (первые 10 матчей) и не повышает общий.

Вариант	Сезон	Группа	Матчи	Δ log loss ×10⁻³ [95 % ДИ]	ROI база	Δ ROI Main, п.п. [95 % ДИ]	Main изм.
Elo новичка −50	2023/24	все матчи	7247	-0.52 [-0.97; -0.06]	-2.1 %	+0.8 [-0.6; +2.2]	18 %
Elo новичка −50	2023/24	новички извне, 1-10	203	-4.60 [-11.52; +2.22]	-6.9 %	+2.5 [-7.4; +11.9]	21 %
Elo новичка −50	2023/24	League Two, новички, 1-10	20	+1.69 [-24.10; +25.34]	-19.9 %	+7.3 [-12.2; +31.5]	15 %
Elo новичка −50	2024/25	все матчи	7129	+0.08 [-0.35; +0.53]	-3.6 %	+0.6 [-0.8; +1.8]	15 %
Elo новичка −50	2024/25	новички извне, 1-10	192	-3.42 [-10.62; +3.44]	-28.2 %	+6.1 [-7.0; +19.3]	28 %
Elo новичка −50	2024/25	League Two, новички, 1-10	19	-3.51 [-24.51; +17.30]	-73.0 %	-27.0 [-81.0; +0.0]	26 %
Elo новичка −50	2025/26	все матчи	7094	-0.47 [-0.92; -0.06]	-6.7 %	+0.0 [-1.3; +1.4]	16 %
Elo новичка −50	2025/26	новички извне, 1-10	155	-7.76 [-15.56; +0.16]	-21.2 %	+0.3 [-11.8; +12.2]	26 %
Elo новичка −50	2025/26	League Two, новички, 1-10	10	-9.63 [-44.72; +25.52]	-39.5 %	+12.1 [+0.0; +56.4]	30 %
Elo новичка −50	все три	все матчи	21470	-0.30 [-0.55; -0.05]	-4.0 %	+0.5 [-0.3; +1.3]	16 %
Elo новичка −50	все три	новички извне, 1-10	550	-5.08 [-9.34; -0.91]	-17.2 %	+2.9 [-3.6; +9.7]	25 %
Elo новичка −50	все три	League Two, новички, 1-10	49	-2.64 [-17.67; +11.97]	-36.0 %	+0.2 [-15.8; +17.4]	22 %
Elo новичка −100	2023/24	все матчи	7247	-0.36 [-1.03; +0.30]	-2.1 %	-1.0 [-2.6; +0.4]	18 %
Elo новичка −100	2023/24	новички извне, 1-10	203	+0.12 [-10.96; +10.92]	-6.9 %	-1.0 [-11.8; +9.3]	26 %
Elo новичка −100	2023/24	League Two, новички, 1-10	20	+15.24 [-25.59; +55.16]	-19.9 %	-2.8 [-41.4; +33.5]	30 %
Elo новичка −100	2024/25	все матчи	7129	+0.03 [-0.61; +0.66]	-3.6 %	-0.0 [-1.3; +1.4]	17 %
Elo новичка −100	2024/25	новички извне, 1-10	192	-9.17 [-21.81; +3.56]	-28.2 %	+0.8 [-13.7; +16.4]	38 %
Elo новичка −100	2024/25	League Two, новички, 1-10	19	-7.92 [-48.95; +33.76]	-73.0 %	-27.0 [-81.0; +0.0]	42 %
Elo новичка −100	2025/26	все матчи	7094	-0.33 [-0.95; +0.24]	-6.7 %	-0.6 [-2.1; +0.9]	18 %
Elo новичка −100	2025/26	новички извне, 1-10	155	-11.12 [-25.02; +2.81]	-21.2 %	-14.7 [-32.0; +1.7]	38 %
Elo новичка −100	2025/26	League Two, новички, 1-10	10	-9.58 [-79.03; +58.09]	-39.5 %	-13.5 [-87.5; +46.6]	30 %
Elo новичка −100	все три	все матчи	21470	-0.22 [-0.58; +0.15]	-4.0 %	-0.5 [-1.4; +0.3]	18 %
Elo новичка −100	все три	новички извне, 1-10	550	-6.29 [-14.03; +1.35]	-17.2 %	-4.2 [-12.1; +3.8]	34 %
Elo новичка −100	все три	League Two, новички, 1-10	49	+1.20 [-28.18; +27.89]	-36.0 %	-7.2 [-36.9; +21.8]	35 %
история ЕС	2023/24	все матчи	7247	+0.10 [-0.20; +0.44]	-2.1 %	-0.2 [-1.4; +0.9]	12 %

Вариант	Сезон	Группа	Матчи	Δ log loss ×10⁻³ [95 % ДИ]	ROI база	Δ ROI Main, п.п. [95 % ДИ]	Main изм.
история ЕС	2023/24	новички извне, 1-10	203	-1.93 [-7.20; +3.91]	-6.9 %	+6.0 [-2.1; +14.3]	20 %
история ЕС	2023/24	League Two, новички, 1-10	20	-16.12 [-69.24; +42.94]	-19.9 %	+60.4 [+19.1; +110.8]	50 %
история ЕС	2024/25	все матчи	7129	+0.13 [-0.12; +0.40]	-3.6 %	-0.7 [-2.0; +0.6]	14 %
история ЕС	2024/25	новички извне, 1-10	192	-1.42 [-3.28; +0.32]	-28.2 %	-0.6 [-11.6; +9.6]	17 %
история ЕС	2024/25	League Two, новички, 1-10	19	-7.58 [-14.85; +0.36]	-73.0 %	+17.0 [-22.3; +74.8]	21 %
история ЕС	2025/26	все матчи	7094	+0.15 [-0.16; +0.46]	-6.7 %	-0.4 [-1.7; +0.8]	12 %
история ЕС	2025/26	новички извне, 1-10	155	+3.09 [-2.65; +10.29]	-21.2 %	+0.4 [-10.0; +10.7]	16 %
история ЕС	2025/26	League Two, новички, 1-10	10	+48.75 [-38.16; +149.97]	-39.5 %	-60.5 [-137.8; +0.0]	60 %
история ЕС	все три	все матчи	21470	+0.12 [-0.04; +0.30]	-4.0 %	-0.4 [-1.1; +0.3]	13 %
история ЕС	все три	новички извне, 1-10	550	-0.34 [-3.27; +2.57]	-17.2 %	+2.4 [-3.0; +7.6]	18 %
история ЕС	все три	League Two, новички, 1-10	49	+0.43 [-28.56; +34.76]	-36.0 %	+26.4 [-9.4; +65.2]	41 %

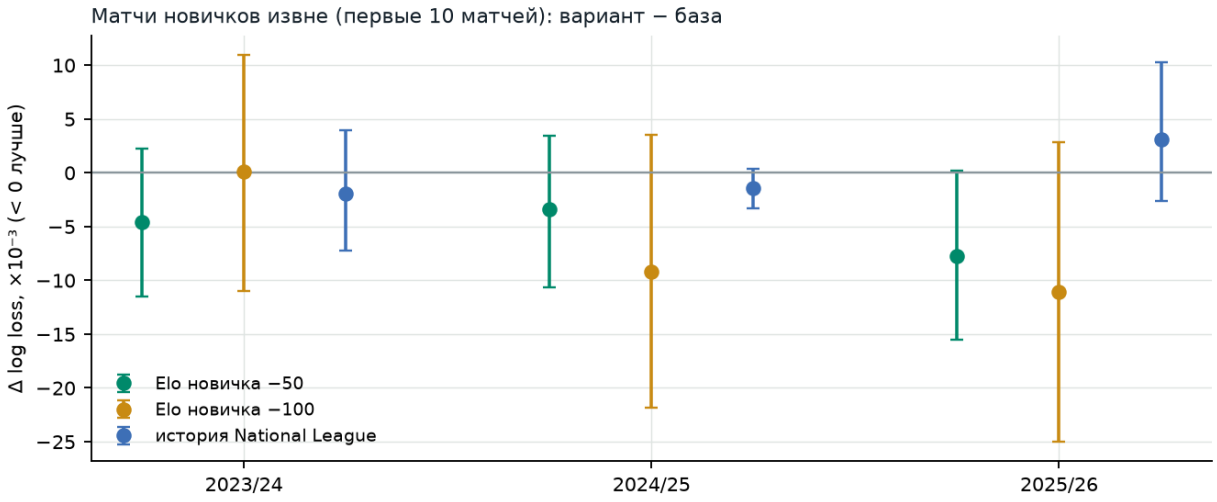


Рис. 8. Изменение log loss матчей новичков извне по сезонам (вариант − база).

Правило отбора выполнено: Elo новичка −50 — нет, Elo новичка −100 — нет, история ЕС — нет. Сезон 2025/26 приведён для информации.

Elo новичка −50 не прошёл объявленное правило только из-за общего log loss 2024/25 (+0.08·10⁻³, интервал [-0.35; +0.53]). На матчах новичков извне log loss ниже во всех трёх сезонах; по трём сезонам вместе: все матчи -0.30·10⁻³ [-0.55; -0.05], новички извне (первые 10) -5.08·10⁻³ [-9.34; -0.91]; ROI Main +0.5 п.п. [-0.3; +1.3]. Этот вывод сделан после просмотра результатов, поэтому вариант — кандидат категории B: его нужно заранее зарегистрировать и проверить на матчах, сыгранных после фиксации гипотезы. Сдвиг −100 слишком велик (2023/24 без улучшения у новичков), история National League почти ничего не даёт.

16. Перечень дефектов

16.1. Ошибки продакшна (исправить)

D1. Разные написания клуба в ФАЙЛАХ РЕЗУЛЬТАТОВ не приводятся к одному имени

Доказательство. 05.11 (коммит 9bd3c19) B1/E1/E2 2026/27 содержали сыгранные матчи «Kortrijk – KV Mechelen», «Preston – Sheffield Utd», «Oxford Utd – Reading»; 06.11 Football-Data исправил. Сутки в признаках были 3 фантомных клуба, а у Mechelen, Sheffield United, Oxford не хватало матча; три фантомных прогноза были рассчитаны (2 проигрыша по цене 2,00 и 1,70, 1 выигрыш без цены).

Исправление. `src/data/dataset.py`: обобщить `harmonise_fixture_names` до `harmonise_names(frame, reference)` и применять его в `build_matches` также к строкам результатов текущего сезона и к строкам API: известные имена лиги = клубы прошлого сезона + клубы текущего сезона с ≥ 3 матчами; имя вне этого набора, которое `aliases.resolve` однозначно сводит к известному, заменяется, match_id пересчитывается. Тест — версии файлов из коммита 9bd3c19.

D2. `team_id_conflicts.csv` не очищается

Доказательство. `collect` пишет файл, только когда конфликты есть (`collect.py`, стр. 460–463); последний раз файл менялся 06.11, конфликт OddsPapi 5044 (Mechelen / «KV Mechelen») — след D1, но отчёт показывает его до сих пор.

Исправление. Как для `unmatched_teams.csv`: при пустом `registry.conflicts` удалять файл (`elif api_storage.exists(...): unlink()`).

D3. Результат, отозванный провайдером, остаётся рассчитанным

Доказательство. SP2-20261102-tenerife-andorra: 03.11 (коммит bf7ccd0) API-Football вернул матч из 2:2 в несыгранные; у Football-Data матча нет. Live Main на SP2-20261101-tenerife-andorra рассчитан как выигрыш +0,378 по цене 1,378 и в истории остаётся.

Исправление. `collect._save_live`: не заменять строку played=True строкой played=False того же match_id без статуса провайдера PST/CANC/ABD (логировать как конфликт). `invariants.check_history`: добавить проверку «рассчитанный прогноз, у матча которого (по id или по паре в пределах 60 дней) нет сыгранной строки», а `store.settle` — возвращать такие прогнозы в UPCOMING.

D4. `rescheduled_duplicates` оставляет прогноз, который нельзя рассчитать

Доказательство. Кластер F1 Nice – Rennes: сыгран 30.10 (5:2); оставлен live-прогноз на 31.10 (UPCOMING, станет VOID), отброшен рассчитанный live-прогноз на 30.10 (Main «меньше 3,5» по 1,46, проигрыш). ROI единой истории занижает число ставок на 1.

Исправление. `src/analytics/performance.py`, `rescheduled_duplicates`: ключ сортировки `[order, unsettled, date desc, generated_at desc]`, где `unsettled = status not in {WON, LOST, PUSH}` — среди записанных прогнозов рассчитанный выигрывает у нерассчитанного.

D5. VOID получает прибыль 0 без цены

Доказательство. 8 записей G1-20261017-atromitos-aek; собственный инвариант `check_history` сообщает «profit without a price». На ROI не влияет.

Исправление. `src/prediction/store.py`, `settle`: для VOID `profit = 0.0 if odds else NaN` (как для PUSH).

D6. Нет псевдонимов для трёх имён API-Football

Доказательство. `unmatched_teams.csv`: «OFI» (G1), «Vicenza Virtus» (I2), «Real Sociedad II» (SP2) — фикстуры и результаты OFI Crete, Vicenza, Sociedad B от API-Football пропускаются.

Исправление. `src/providers/aliases.py`, `TEAM_ALIASES`: `"ofi": "OFI Crete"`, `"vicenza virtus": "Vicenza"`, `"real sociedad ii": "Sociedad B"`.

Исторический дефект, уже исправленный 22.10: API-Football 16–22.10 записал St Johnstone – Dundee United как St Johnstone – Dundee (фантомный результат 1:1 пять дней был в признаках Dundee).

16.2. Исследовательские наблюдения

- Клубы из лиг, которые система не загружает, стартуют со средним Elo лиги (база уровня), хотя набирают меньше очков; в первых матчах модель их переоценивает.
- Edinburgh City / FC Edinburgh — один клуб под двумя именами (история разорвана в 2022/23 и 2023/24).
- Технические победы 3:0 (Турция 2022/23 — 29 матчей) идут в форму и Elo как сыгранные матчи.
- Плей-офф Бельгии и Греции смешан с регулярным сезоном в признаках «по сезону».
- Отложенные матчи без новой даты висят в таблице признаков как фикстуры с прошедшей датой (9 строк).
- Main неустойчив к сдвигам вероятностей: пустая группа признаков у одной стороны меняет его в 28 %–74 % матчей, но ROI Main при этом в пределах шума.

17. Отрицательные результаты

- Независимый пересчёт не нашёл ни одного расхождения в признаках — ошибок вычисления нет.
- Сопоставление API с Football-Data: ни одного переставленного хозяина/гостя, ни одного расхождения счёта или времени начала у совпавших матчей.
- Задержка результатов почти не влияет на live-прогнозы: 1 из 826.
- Индекс качества данных почти не связан с избыточным log loss (Спирмен 0.022); разность ROI Main между матчами с > 20 % пропусков и без пропусков +0.9 п.п. [-8.0; +10.2] — в пределах шума, интервал включает 0.
- Не прошли объявленное правило отбора: Elo новичка −50, Elo новичка −100, история National League.

18. Ограничения

- История git покрывает только 24.09–09.11.2026: дефекты имён в более ранних сезонах видны лишь по итоговым файлам.
- Новичков извне немного (14–28 клубов в сезон), интервалы по ROI широкие.
- Настоящий результат Tenerife – Andorra локально неизвестен: сеть не использовалась.
- Порча признаков — модель реального дефекта; в жизни пустые признаки встречаются вместе с особенностями клуба (слабее, новый состав), которых порча не воспроизводит.
- 2026/27 не является нетронутой проверкой; 2025/26 — для информации.

19. Выводы

- **H1 подтверждается.** Найдено 6 ошибок продакшна (D1–D6) и один исторический дефект; самый опасный — D1 (разные написания в файлах результатов). Его последствия сейчас гасит `same_day_duplicates`, но признаки клубов сутки были неверны и фантомы были рассчитаны.
- **H2 подтверждается.** Признаки вычислены верно (0 расхождений).
- **H3 подтверждается для вероятностей.** Пустые признаки одной стороны заметно сдвигают вероятности, ухудшают log loss и меняют Main; ROI Main при этом в пределах шума.
- **H4 частично.** Матчи новичков извне хуже по log loss (интервал не включает 0), но против рынка разница +10.4 [-4.7; +25.2]·10^{-3} — в пределах шума, интервал включает 0; ROI Main -7.8 п.п. [-17.4; +2.3] — в пределах шума, интервал включает 0.

Систематическая переоценка новичков в первых матчах есть.

- **H5 не подтверждается** в заметном объёме: индекс пропусков слабо связан с ошибкой и ROI.
- **H6 не подтверждена по объявленному правилу:** ни один вариант его не выполнил. Elo новичка −50 улучшает log loss устойчиво (вывод после просмотра — категория B).

20. Рекомендации

Рекомендация	Категория	Основание
D1: приводить имена в строках результатов и API к именам лиги	A	раздел 7.1, 11.1
D3: не откатывать результат в фикстуру без статуса; инвариант «рассчитан без результата»	A	раздел 8, 11.3
D4: в `rescheduled_duplicates` рассчитанный прогноз важнее поздней даты	A	раздел 11.2
D2: удалять `team_id_conflicts.csv`, когда конфликтов нет	A	раздел 7.2
D5: VOID без цены — прибыль NaN	A	раздел 11.3
D6: три псевдонима API-Football	A	раздел 7.2
Таблица переименований клубов (FC Edinburgh → Edinburgh City) в нормализации	A	раздел 7.3
Помечать технические 3:0 и не учитывать их в форме и Elo	B	раздел 6; эффект на прогноз не измерен
Стартовый Elo новичка извне −50	B	раздел 15; правило не выполнено, но улучшение устойчиво во всех сезонах — перерегистрация и проверка вперёд
Стартовый Elo новичка извне −100	C	раздел 15; правило отбора не выполнено
История National League в состоянии строителя	C	раздел 15; правило отбора не выполнено
Флаг «мало данных» на карточке матча, когда у клуба < 5 матчей в наших лигах	B	раздел 12–13: прогноз и Main меняются; ROI-эффект в пределах шума
Отбрасывать Main на матчах с высоким индексом пропусков	C	раздел 14: связи с ROI нет

A — готово к внедрению; B — перспективно, нужна проверка на будущих матчах; C — не рекомендуется. Исследование само ничего в продакшне не меняет.

21. Воспроизведение

Команды воспроизведения (из корня репозитория, окружение `.venv`):

```
python -m experiments.v6_2.data_quality.run          # все шаги, ~30–40 мин, 2 потока
python -m experiments.v6_2.data_quality.run --only raw_audit teams recompute store_audit
python -m experiments.v6_2.data_quality.figures
python -m experiments.v6_2.data_quality.build_pdf
```

Кэш (`experiments/v6_2/data_quality/cache/`, не в git): переобученные модели, прогнозы по сезонам, испорченные прогнозы, пересобранные признаки вариантов. Результаты — JSON и CSV в `results/`; окружение и версия данных — `results/run_info.json`.